

补充材料 01：VLA 架构选型分析

核心问题

端到端 VLA、模块化 VLA、层次化 VLA 三种架构范式，在工业分拣配送场景下各有什么优劣？我们为什么选择层次化 VLA 作为方案的技术路线？

一、三种架构的本质区别

说明：学术界对 VLA 架构的主流分类为"端到端 VLA"与"模块化 VLA"两大类。本文在此基础上将模块化 VLA 进一步细分为"传统管道式模块化"和"层次化模块化（Hierarchical VLA）"，后者是本方案选用的技术路线。以下三种架构的并列比较，是为了分析的便利性，不代表行业共识分类标准。

- 端到端 VLA：**一个神经网络，像素/文字进，关节角度出，中间没有人类可读的表示层。代表性模型：RT-2、 $\pi 0.5$ 、OpenVLA、LingBot-VLA 2.0。
- 模块化 VLA：**VLA 负责理解+规划，动作由下游模块（控制策略/运动规划器）执行，中间有明确接口。各模块独立开发、独立验证。
- 层次化 VLA (Hierarchical VLA)：**模块化 VLA 的一种特定设计模式——VLA 负责高频多变的"软决策"（技能选择+目标参数的生成），经典控制负责低频确定的"硬执行"（轨迹跟踪+力控伺服）。关键区别在于 VLA 不直接输出动作指令，而是输出受约束的"意图参数"。

端到端 VLA：

[摄像头画面 + "把红色料箱放到B区"] → 一个巨型模型 → [关节1转15°，关节2转-8°，...]

模块化 VLA：

[摄像头画面 + "把红色料箱放到B区"] → VLA模型 → [结构化任务图/子目标]

↓

[抓取策略] [运动规划] [力控模块] → 关节

指令

层次化 VLA：

[摄像头画面 + "把红色料箱放到B区"] → VLA模型 → [技能选择 + 目标参数]

↓

[Skill Policy: 经典运动规划+力控] → 关

节指令

二、端到端 VLA 的优劣分析

优势

- 没有信息瓶颈：**模型内部保留全部感知信息（包括"物体表面有水渍很滑"这类隐式线索），不需要在模块边界做有损压缩。
- 动作流畅度极好：**端到端 VLA 的一个关键特性是模型内部学到的隐式"恢复"能力——在执行过程中遇到偏差时不依赖外部重规划，而是自主做出微调，表现出流畅的类人操作风格。这在 $\pi 0.5$ 等模型的公开 demo 中有明显体现。
- 泛化潜力最大：**当训练数据足够大时，端到端模型能在全新场景输出"合理"动作，基于内部表征空间的联想泛化。

劣势（工业场景致命短板）

- 1. **不可解释**：抓取失败后无法区分是"识别错"还是"规划错"还是"控制错"。不满足 ISO 10218-1 工业安全可追溯要求。
- 2. **无法表达不确定性**：端到端模型总是输出一个动作，不会说"我没见过这个物体，不知道怎么处理"。
- 3. **验证不完备**：输入空间（所有可能的图像+语言组合）是无穷的，无法在上线前穷举验证安全性。
- 4. **长序列短视**：每步基于当前观测决策，没有显式全局计划。第 3 步的抓取姿态不好导致第 6 步放不进去——模型在第 3 步时意识不到。

三、模块化 VLA 的优劣分析

优势

- 1. **可追溯**：每个模块有明确输入输出，事故后可定位故障模块。
- 2. **可约束**：安全规则可精确插在模块间（如"料箱重量 < 负载上限"的硬拦截）。
- 3. **可增量开发**：新操作只需添加新技能模块，VLA 理解层不用改。

劣势

- 1. **信息在模块边界丢失**：感知模块输出"红色料箱"，丢掉了"表面反光、左上角凹陷、标签翘起"等对抓取重要的细节。
- 2. **接口僵化**：人类定义的接口可能漏掉关键信息通道。
- 3. **反应速度不如端到端**：感知→规划→控制串行延迟，不适合动态抓取。

四、我们的选择：层次化 VLA（Hierarchical VLA）

分工逻辑

	VLA（软决策层）	Skill Policy（硬执行层）
做什么	物体识别、意图理解、技能选择、目标参数生成	轨迹规划、力控伺服、碰撞检测、安全保护
特点	需要泛化、处理变化、可容忍一定不确定性	需要确定性、实时性、安全性
运行在哪	SRC-5000 的 156TOPS AI 芯片	SRC-5000 的 RTOS+TSN 实时核
更新频率	可迭代更新（LoRA微调、联邦学习）	出厂固化（严格验证后不轻易改动）

为什么这样选？

- 1. **VLA 做它最擅长的**：视觉理解、语义理解、策略选择——这些是传统视觉+规则系统做不好的。
- 2. **经典控制做它最擅长的**：轨迹跟踪、力控、碰撞检测——这些是 VLA 做不好但传统控制做得很成熟的。
- 3. **与仙工 SRC-5000 硬件天然对齐**：156TOPS AI 芯片 + RTOS+TSN 实时核 + EtherCAT 总线，为层次化架构提供了完美硬件载体。

4. **安全边界清晰**：VLA 输出的是"意图"（选哪个技能、目标在哪），不是"动作"（关节转多少度）。即使 VLA 出错，硬件安全层仍有最后一道防线。

五、结论

- **端到端 VLA 是科研的理想形态，层次化 VLA 是工业的当前答案。**
- 题目选 VLA 做控制核心，不是因为端到端比模块化更先进，而是 VLA 的视觉-语言-动作统一建模能力是传统"感知→规划→控制"管道做不到的。
- 但这并不意味着要把安全验证和运动控制也塞进 VLA。

前瞻：VLA 与 World Action Model 的融合趋势

2026 年的一个显著技术趋势是 VLA 与世界动作模型（World Action Model, WAM）的融合。代表性进展包括：

- **InternVLA-A1.5**（上海 AI Lab, 2026.07）：在 VLA 框架中引入"隐式预见"（latent foresight），让模型在动作生成前预测未来状态，六项仿真基准全部最佳。
- **Being-M0.7**（智在无界, 2026.07）：全球首个面向人形机器人全身移动操作的隐式世界动作模型，采用"低频规划+高频控制解耦"——即高层生成未来状态规划，低层动作专家以高频生成可执行动作。
- **Kairos**（ACE Robotics, 2026.06）：以 4B 参数的世界模型在 LIBERO-Plus 上首次超越所有 VLA 系统（89.0 vs ACoT-VLA 88.0）。

这些进展的方向与我们的层次化 VLA 架构高度一致——"高层负责任务理解与策略选择，低层负责轨迹生成与安全执行"的分层设计，天然适配未来在 VLA 中加入世界模型预测能力的技术演进路径。换言之，**层次化 VLA 不仅是工业的当前答案，也是面向下一代具身智能架构的预留接口。**

参考文献

- RT-2 (Google DeepMind, 2023.07): "RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control", arXiv:2307.15818
- π 0.5 (Physical Intelligence, 2025.04): " π 0.5: A Vision-Language-Action Flow Model for General Robot Control", arXiv:2504.16054
- OpenVLA (Stanford et al., 2024): "OpenVLA: An Open-Source Vision-Language-Action Model"
- LingBot-VLA 2.0 (Robbyant/Ant Group, 2026.07): 开源具身智能通用大脑，20 种机器人构型，17 家厂商
- ISO 10218-1: 工业机器人安全要求